

Grok Bot: onde rodar, para que serve e quanto custa

Comparativo de seis caminhos para um bot baseado na API da xAI (Grok), com escala de impacto, preços oficiais por token e cenários mensais. Valores de outubro de 2026.

Resumo executivo

Recomendação. Construir o bot como um módulo dentro do via-hub, no domínio próprio iniciativa-via.com, com um proxy em **Cloudflare Workers** que guarda a chave da xAI e passa pelo **AI Gateway** (registros, limite de requisições e controle de gasto). É o caminho de menor custo fixo (US\$ 0 a US\$ 5/mês de hospedagem), sem cobrança de tráfego, e reaproveitável depois para Telegram, WhatsApp ou um GitHub App sem refazer o núcleo.

Ordem de grandeza. Com o modelo recomendado (grok-4.6), uma mensagem típica custa cerca de US\$ 0,00700 (R\$ 0,0385); com grok-4.3, US\$ 0,00375. Dez mil mensagens por mês com grok-4.6 e Workers pago somam aproximadamente US\$ 75,00 (R\$ 412,50).

O que este documento responde

- Onde o bot pode ser exibido e executado (seis opções) e para que cada uma é ideal.
- Força do impacto e ganho potencial de qualidade, em escala de 1 a 5, com justificativa.
- Preço por token dos modelos Grok e das plataformas de hospedagem, com fontes oficiais.
- Custo mensal estimado em 1.000, 10.000 e 100.000 mensagens, com e sem busca na web.
- Riscos de conformidade (LGPD, dados de saúde, termos do WhatsApp) e próximos passos.

Ponto técnico crítico: a chave nunca vai para o site

O via-hub é servido pelo GitHub Pages, que entrega apenas arquivos estáticos. Qualquer chave colocada no HTML ou no JavaScript fica visível para qualquer visitante, que poderia usá-la e gerar cobrança. Por isso, **toda opção web exige um intermediário no servidor** (um Worker da Cloudflare ou uma Function da Vercel) que guarda a **XAI_API_KEY** como segredo, recebe a pergunta do navegador, aplica limites e só então chama a xAI.

Navegador (via-hub, iniciativa-via.com) → proxy no servidor (Worker/Function, guarda a chave, aplica limites) → AI Gateway (registros, cache, teto de gasto) → API da xAI (Grok)

Os termos do GitHub Pages também proíbem uso primariamente comercial ou como serviço (SaaS) e transações sensíveis. Um bot institucional e informativo, com o processamento fora do Pages, é compatível; cobrança de usuários ou coleta de dados sensíveis pelo site não é.

1. Opções de onde e como o bot é renderizado

As opções não são excludentes. A arquitetura recomendada separa a **interface** (site, WhatsApp, Telegram, GitHub) do **núcleo** (proxy com a chave, instruções do bot e limites), de modo que um mesmo núcleo atenda vários canais.

Opção	Onde é renderizado	Ideal para	Impacto	Complexidade
A. Módulo no via-hub	Página ou widget de chat no próprio site (GitHub Pages, domínio iniciativa-via.com); requer proxy.	Presença pública da VIA, letramento digital, perguntas sobre o manifesto, o pipeline e os projetos.	4/5	2/5
B. GitHub App	Bot que comenta em issues e pull requests do repositório; servidor recebe webhooks.	Triagem de issues, revisão de PRs, checagem de textos e de consistência do site.	3/5	3/5
C. Cloudflare Workers + AI Gateway	Não é uma interface: é o servidor que guarda a chave e atende A, B, E e F.	Proxy seguro, limites de uso, registros e teto de gasto com o menor custo fixo.	5/5	2/5
D. Vercel (Functions + AI SDK / AI Gateway)	Servidor alternativo; pode também hospedar uma interface Next.js própria.	Interface de chat mais rica (streaming, histórico) com o AI SDK; equipe já habituada a Next.js.	3/5	3/5
E. WhatsApp Business	Conversa no WhatsApp, no número institucional +55 16 99618-0196 (via Cloud API da Meta ou Twilio).	Atendimento institucional a quem não navega em sites: dúvidas frequentes, agenda, encaminhamento a humano.	5/5	4/5
F. Telegram	Conversa em bot do Telegram, criado via @BotFather; webhook no Worker.	Protótipo rápido e gratuito, grupos de estudo, testes internos antes do WhatsApp.	2/5	1/5

Escala de impacto (ganho potencial de qualidade e alcance)

Nota	Significado
1	Ganho marginal; útil apenas para teste ou para um grupo muito restrito.
2	Ganho localizado; alcance pequeno ou público já atendido por outros meios.
3	Ganho claro em uma frente (técnica ou de comunicação), com alcance moderado.
4	Ganho relevante e visível para o público da VIA, sob marca própria.
5	Ganho estrutural: viabiliza outras frentes ou alcança o maior público possível.

Complexidade segue a mesma escala (1 = configuração simples; 5 = integração com aprovação de terceiros, políticas e operação contínua). A execução técnica fica a cargo do agente; a nota indica esforço e risco, não tarefa para o mantenedor.

Justificativa das notas

A. Módulo no via-hub — 4/5. Alcança quem já visita o site, sob a marca e o domínio da VIA, com conteúdo curado. Não chega a quem não visita o site.

B. GitHub App — 3/5. Ganho de qualidade técnica real, mas interno e parcialmente sobreposto a Codex e Copilot, já usados no repositório.

C. Cloudflare Workers + AI Gateway — 5/5. É a peça que viabiliza com segurança todas as outras opções; sem cobrança de tráfego e com plano gratuito generoso.

D. Vercel (Functions + AI SDK / AI Gateway) — 3/5. Mesmo resultado funcional do Workers, com custo fixo maior (Pro US\$ 20/assento); Hobby não admite uso comercial.

E. WhatsApp Business — 5/5. Maior alcance no Brasil, mas com custo por mensagem, aprovação da Meta e restrição a assistentes de uso geral.

F. Telegram — 2/5. API gratuita e simples, porém com alcance bem menor que o WhatsApp no público brasileiro.

2. Detalhes por plataforma

GitHub Pages (interface da opção A)

- Suporta domínio próprio com HTTPS — o via-hub já usa iniciativa-via.com/via-hub/.
- Limites: site de até 1 GB e cerca de 100 GB/mês de banda (limite flexível). Um widget de chat é leve.
- Não executa código no servidor: não guarda segredos e não chama a xAI diretamente.
- Não se destina a SaaS, comércio eletrônico ou transações sensíveis.

GitHub App (opção B)

- Permissões finas por repositório, tokens de curta duração e identidade de bot que não ocupa assento pago.
- Recebe eventos issues, pull_request e issue_comment por webhook; precisa de um servidor para recebê-los (o mesmo Worker ou Function).
- Conforme AGENTS.md, comentários do bot não contam como revisão independente nem autorizam merge.

Cloudflare Workers + AI Gateway (opção C)

- Free: 100 mil requisições/dia e 10 ms de CPU por requisição. A espera pela resposta da xAI não conta como CPU.
- Paid: US\$ 5/mês com 10 milhões de requisições e 30 milhões de CPU-ms incluídos; excedente de US\$ 0,30 por milhão de requisições e US\$ 0,02 por milhão de CPU-ms. **Sem cobrança de tráfego de saída (egress).**
- AI Gateway: análise de uso, cache e limitação de requisições gratuitos; registros de 100 mil (Free) ou 10 milhões por gateway (Paid). Unified Billing cobra 5% sobre créditos comprados, sem acréscimo por token; com chave própria da xAI, essa taxa não se aplica.

Vercel (opção D)

- Hobby: gratuito, apenas uso pessoal e não comercial; 1 milhão de invocações, 4 h de CPU e 360 GB-h; ao exceder, o projeto é pausado.
- Pro: US\$ 20/mês por assento, com US\$ 20 de crédito de uso. Invocações a US\$ 0,60/milhão; CPU ativa ≈ US\$ 0,128/h (iad1, EUA) e ≈ US\$ 0,221/h (gru1, São Paulo).
- AI Gateway da Vercel: sem acréscimo sobre tokens, inclusive com chave própria (BYOK, que exige créditos comprados); crédito mensal gratuito no plano free; orçamentos por projeto.

WhatsApp Business (opção E)

- Desde 01/10/2026 a Meta cobra por **mensagem de serviço** (resposta dentro da janela de 24 h aberta pelo usuário), com **1.000 mensagens de serviço gratuitas por mês por número** (fonte oficial Meta). Templates de utilidade dentro da janela também passam a ser cobrados.
- Valor de lista no Brasil: R\$ 0,035 por mensagem de serviço em conta faturada em reais (≈ US\$ 0,0068 em conta em dólar). **Este valor foi confirmado apenas em fontes secundárias;** a tabela oficial (rate card) da Meta é um arquivo para download e deve ser conferida antes da decisão.
- Via Twilio há taxa adicional por mensagem, **não verificada** nesta revisão. A Cloud API direta da Meta não tem essa taxa intermediária.

- Termos da Meta (desde 15/01/2026) proíbem provedores de IA de oferecer assistente de **uso geral** como função principal no WhatsApp Business; uso empresarial com escopo definido continua permitido. Há exceção atual para números do Brasil e do EEE, sujeita a mudança.

Telegram (opção F)

- Bot API gratuita; o bot é criado no @BotFather e ligado ao Worker por webhook (HTTPS, portas 443/80/88/8443).
- Limites de envio: cerca de 1 mensagem/s por conversa, 20/min em grupos e 30/s em difusão. Difusão paga (Telegram Stars) só se aplica a bots com mais de 100 mil usuários ativos mensais.

3. Quanto custa: preço por token

Preços da xAI em dólares por **1 milhão de tokens**, para prompts abaixo de 200 mil tokens. Um token equivale, em média, a cerca de três quartos de uma palavra em inglês; em português, a proporção é um pouco menor.

Modelo	Entrada	Entrada em cache	Saída	Contexto	Observação
grok-4.6	US\$ 2,00	US\$ 0,50	US\$ 6,00	500k	Recomendado pela xAI para tudo, exceto mídia
grok-4.5	US\$ 2,00	US\$ 0,30	US\$ 6,00	—	Geração anterior
grok-4.3	US\$ 1,25	US\$ 0,20	US\$ 2,50	1M	Mais barato; contexto maior
grok-4.20	US\$ 1,25	US\$ 0,20	US\$ 2,50	1M	Variantes com e sem raciocínio
grok-build-0.1	US\$ 1,00	US\$ 0,20	US\$ 2,00	—	Voltado a código

grok-4.6 com prompts a partir de 200 mil tokens: US\$ 4,00 entrada, US\$ 1,00 cache, US\$ 12,00 saída. A Batch API (processamento não imediato) tem desconto.

Ferramentas executadas no servidor da xAI

Ferramenta	Preço	Por chamada	Uso típico no bot
web_search, x_search, code_execution	US\$ 5,00 / 1.000	US\$ 0,0050	Buscar informação atual na web ou no X
attachment_search	US\$ 10,00 / 1.000	US\$ 0,0100	Buscar dentro de arquivos anexados
collections_search (RAG)	US\$ 2,50 / 1.000	US\$ 0,0025	Responder com base nos documentos da VIA

Controle de custo na prática

- Cada resposta da xAI informa o custo real da requisição no campo **usage.cost_in_usd_ticks**; o proxy pode somar esse valor e bloquear novas chamadas ao atingir um teto diário ou mensal.
- Usar **prompt_cache_key** para que o prompt de sistema e o histórico estável sejam cobrados como entrada em cache (US\$ 0,50 em vez de US\$ 2,00 por milhão no grok-4.6).
- Limitar o tamanho das respostas e o número de chamadas de ferramenta por mensagem.

4. Quanto custa: cenários mensais

Premissas. Mensagem típica com 2.000 tokens de entrada (instruções do bot, histórico e pergunta) e 500 tokens de saída. Web search: 1 chamada por mensagem (US\$ 0,005). Linha com cache: 1.500 dos 2.000 tokens de entrada cobrados como cache. Conversão: **US\$ 1 = R\$ 5,50** (premissa arredondada, não cotação oficial; impostos sobre serviços digitais e IOF do cartão não incluídos). Workers: 5 ms de CPU por requisição; Vercel: 50 ms de CPU ativa em gru1.

Custo de tokens (xAI)

Modelo e ferramentas	Por mensagem	1.000 msg/mês	10.000 msg/mês	100.000 msg/mês
grok-4.6	US\$ 0,00700	US\$ 7,00 R\$ 38,50	US\$ 70,00 R\$ 385,00	US\$ 700,00 R\$ 3.850,00
grok-4.6 + web search	US\$ 0,01200	US\$ 12,00 R\$ 66,00	US\$ 120,00 R\$ 660,00	US\$ 1.200,00 R\$ 6.600,00
grok-4.6 com cache (1.500 tokens)	US\$ 0,00475	US\$ 4,75 R\$ 26,12	US\$ 47,50 R\$ 261,25	US\$ 475,00 R\$ 2.612,50
grok-4.3	US\$ 0,00375	US\$ 3,75 R\$ 20,62	US\$ 37,50 R\$ 206,25	US\$ 375,00 R\$ 2.062,50
grok-4.3 + web search	US\$ 0,00875	US\$ 8,75 R\$ 48,12	US\$ 87,50 R\$ 481,25	US\$ 875,00 R\$ 4.812,50

Custo de hospedagem e canal

Hospedagem e canal (somar ao custo de tokens)	1.000 msg/mês	10.000 msg/mês	100.000 msg/mês
Cloudflare Workers Free (até 100 mil req/dia)	US\$ 0,00	US\$ 0,00	US\$ 0,00
Cloudflare Workers Paid (recomendado)	US\$ 5,00	US\$ 5,00	US\$ 5,00
Vercel Pro, 1 assento	US\$ 20,00	US\$ 20,00	US\$ 20,00
Telegram Bot API	US\$ 0,00	US\$ 0,00	US\$ 0,00
WhatsApp, mensagens de serviço*	US\$ 0,00	US\$ 61,20	US\$ 673,20
GitHub Pages (interface)	US\$ 0,00	US\$ 0,00	US\$ 0,00

* WhatsApp: 1.000 mensagens de serviço grátis por mês e US\$ 0,0068 por mensagem excedente (valor de fontes secundárias; não inclui taxa de Twilio ou outro intermediário, não verificada). Considera uma resposta do bot por mensagem do usuário. Na Vercel, o uso estimado (US\$ 0,37 em 100 mil mensagens) fica dentro do crédito de US\$ 20 do plano Pro.

Total mensal (tokens + hospedagem + canal)

Total mensal estimado	1.000 msg/mês	10.000 msg/mês	100.000 msg/mês
Site + Workers Paid + grok-4.6	US\$ 12,00 R\$ 66,00	US\$ 75,00 R\$ 412,50	US\$ 705,00 R\$ 3.877,50
Site + Workers Paid + grok-4.6 + web search	US\$ 17,00 R\$ 93,50	US\$ 125,00 R\$ 687,50	US\$ 1.205,00 R\$ 6.627,50
Site + Workers Paid + grok-4.3	US\$ 8,75 R\$ 48,12	US\$ 42,50 R\$ 233,75	US\$ 380,00 R\$ 2.090,00
Site + Vercel Pro + grok-4.6	US\$ 27,00 R\$ 148,50	US\$ 90,00 R\$ 495,00	US\$ 720,00 R\$ 3.960,00
WhatsApp + Workers Paid + grok-4.6*	US\$ 12,00 R\$ 66,00	US\$ 136,20 R\$ 749,10	US\$ 1.378,20 R\$ 7.580,10
Telegram + Workers Paid + grok-4.6	US\$ 12,00 R\$ 66,00	US\$ 75,00 R\$ 412,50	US\$ 705,00 R\$ 3.877,50

GitHub App (opção B): referência separada

Revisões de pull request usam contexto maior. Premissa: 300 eventos/mês, 20.000 tokens de entrada e 2.000 de saída cada, com grok-4.6: US\$ 0,052 por evento, cerca de **US\$ 15,60/mês** (R\$ 85,80), mais a hospedagem do webhook (Workers Free ou Paid).

5. Riscos e conformidade

Dados de saúde e LGPD

- Dados de saúde são **dados pessoais sensíveis** (LGPD, art. 5º, II, e art. 11). O bot **não deve receber nem enviar à xAI dados identificáveis de pacientes**: nome, CPF, prontuário, datas, telefone, imagens ou relatos que permitam identificar alguém.
- Avisar na interface, antes do primeiro uso, que o bot é informativo, não faz diagnóstico nem substitui consulta, e que não se deve digitar dados de pacientes.
- O proxy pode aplicar filtro simples (CPF, telefone, e-mail) e recusar a mensagem antes do envio à xAI.
- Publicar política de privacidade do bot: o que é registrado, por quanto tempo, e que o processamento ocorre fora do Brasil (transferência internacional, LGPD art. 33). Configurar retenção curta de registros no AI Gateway.
- A conduta ética médica (CFM) também se aplica à comunicação pública de um médico: o bot não deve prometer resultados nem fazer orientação clínica individual.

HUMAN_GATE

- Respostas sobre condutas clínicas, casos individuais ou temas jurídicos devem encaminhar a um humano em vez de responder.
- No GitHub App, o bot comenta e sugere; merge e publicação continuam sendo decisão do mantenedor (AGENTS.md).
- Mudanças nas instruções do bot (prompt de sistema) passam por PR revisado, como o restante do site.

Gasto e abuso

- Teto de gasto em três camadas: limite de crédito na conta xAI, limitação de requisições no AI Gateway e contador de **cost_in_usd_ticks** no proxy que bloqueia ao atingir o teto.
- Limite por visitante (por exemplo, 20 mensagens/hora) e Cloudflare Turnstile contra robôs.
- A chave da xAI existe apenas como segredo do servidor; nunca no repositório, que é público.

Plataformas

- GitHub Pages: uso institucional e informativo; nada de cobrança ou SaaS hospedado no Pages.
- Vercel Hobby: vedado para uso comercial; se a VIA tiver caráter comercial, usar Pro.
- WhatsApp: manter o bot com escopo institucional definido (não um assistente de uso geral), cumprir opt-out e política de mensagens; risco de suspensão do número se os termos forem violados. Recomenda-se um número dedicado ao bot para não arriscar o número principal.

6. Próximos passos

O que depende do mantenedor

#	Decisão ou ação	Por que só o mantenedor pode fazer
1	Criar conta na xAI (console.x.ai), cadastrar forma de pagamento, definir limite de crédito e gerar a XAI_API_KEY.	Conta, pagamento e aceite de termos são pessoais.
2	Adicionar a chave como segredo: Cursor Dashboard → Cloud Agents → Secrets (nome XAI_API_KEY). O agente a transfere para o segredo do Worker sem expô-la.	Envolve credencial e cobrança.
3	Escolher o canal inicial: site (recomendado), Telegram, WhatsApp ou GitHub App.	Decisão substantiva de produto.
4	Definir o teto de gasto mensal (por exemplo, US\$ 20) e o escopo do bot (o que responde e o que encaminha).	Decisão de orçamento e de conteúdo.
5	Se escolher Cloudflare: criar conta ou autorizar acesso do agente; se WhatsApp: conta Meta Business verificada e número dedicado.	Contas de terceiros e infraestrutura externa (HUMAN_GATE).

O que o agente executa depois das decisões

- Worker proxy com a chave como segredo, AI Gateway, limites, filtro de dados pessoais e teto por **cost_in_usd_ticks**.
- Módulo de chat no via-hub com aviso de uso, seguindo a identidade visual do site, em PR draft para revisão.
- Prompt de sistema com o conteúdo da VIA e regras de encaminhamento humano, versionado no repositório.
- Testes com volume pequeno e relatório de custo real antes de abrir ao público.
- Expansão para Telegram, WhatsApp ou GitHub App reaproveitando o mesmo núcleo, conforme decisão.

Fontes consultadas

- xAI — Models and Pricing: docs.x.ai/developers/pricing (preços por token, ferramentas, cost_in_usd_ticks, cache).
- Cloudflare Workers — Pricing: developers.cloudflare.com/workers/platform/pricing.
- Cloudflare AI Gateway — Pricing: developers.cloudflare.com/ai-gateway/reference/pricing.
- Vercel — Pricing e Fair use: vercel.com/pricing; vercel.com/docs/limits/fair-use-guidelines.
- Vercel AI Gateway — Pricing: vercel.com/docs/ai-gateway/pricing.
- GitHub Pages — Limits e uso: docs.github.com/pages/getting-started-with-github-pages/github-pages-limits.
- GitHub Apps — About creating GitHub Apps: docs.github.com/apps/creating-github-apps.
- Meta — Pricing on the WhatsApp Business Platform: developers.facebook.com/documentation/business-messaging/whatsapp/pricing (cobrança de mensagens de serviço e franquia de 1.000/mês a partir de 01/10/2026).
- WhatsApp Business Solution Terms, seção AI Providers: whatsapp.com/legal/business-solution-terms.
- Valor R\$ 0,035 / US\$ 0,0068 por mensagem de serviço no Brasil: fontes secundárias (wizebot.com.br, clickmassa.com.br) que reproduzem o rate card oficial de 01/10/2026 — conferir no rate card da Meta.
- Telegram — Bots FAQ: core.telegram.org/bots/faq (API gratuita, limites de envio).
- LGPD — Lei nº 13.709/2018, arts. 5º, 11 e 33.

Não verificado nesta revisão: taxa por mensagem da Twilio para WhatsApp; rate card oficial da Meta em arquivo (valor em reais obtido de fontes secundárias); cotação do dólar (usada como premissa). Preços mudam; revalidar antes de contratar. Preços coletados em 02/10/2026 por agente de IA a partir de `grok/bot/gerar_pdf_opcoes.py`.