

Grok Bot: onde rodar, para que serve e quanto custa

Comparativo de seis caminhos para um bot baseado na API da xAI (Grok), com escala de impacto, preços oficiais por token e cenários mensais. Valores de outubro de 2026.

Resumo executivo

Recomendação. Construir o bot como um módulo dentro do via-hub, no domínio próprio iniciativa-via.com, com um proxy em **Cloudflare Workers** que guarda a chave da xAI e passa pelo **AI Gateway** (registros, limite de requisições e controle de gasto). É o caminho de menor custo fixo (US\$ 0 a US\$ 5/mês de hospedagem), sem cobrança de tráfego, e reaproveitável depois para Telegram, WhatsApp ou um GitHub App sem refazer o núcleo.

Ordem de grandeza. Com o modelo recomendado (grok-4.6), uma mensagem típica custa cerca de US\$ 0,00700 (R\$ 0,0379); com grok-4.3, US\$ 0,00375. Dez mil mensagens por mês com grok-4.6 e Workers pago somam aproximadamente US\$ 75,00 (R\$ 405,98). Valores em reais a US\$ 1 = R\$ 5,23 (02/10/2026) com IOF de 3,5%.

O que este documento responde

- Onde o bot pode ser exibido e executado (seis opções) e para que cada uma é ideal.
- Força do impacto e ganho potencial de qualidade, em escala de 1 a 5, com justificativa.
- Preço por token dos modelos Grok e das plataformas de hospedagem, com fontes oficiais.
- Custo mensal estimado em 1.000, 10.000 e 100.000 mensagens, com e sem busca na web.
- Como imprimir a tabela de custos por comando de voz (Alexa), com orçamento em três níveis.
- Riscos de conformidade (LGPD, dados de saúde, termos do WhatsApp) e próximos passos.

Ponto técnico crítico: a chave nunca vai para o site

O via-hub é servido pelo GitHub Pages, que entrega apenas arquivos estáticos. Qualquer chave colocada no HTML ou no JavaScript fica visível para qualquer visitante, que poderia usá-la e gerar cobrança. Por isso, **toda opção web exige um intermediário no servidor** (um Worker da Cloudflare ou uma Function da Vercel) que guarda a **XAI_API_KEY** como segredo, recebe a pergunta do navegador, aplica limites e só então chama a xAI.

Navegador (via-hub, iniciativa-via.com) → proxy no servidor (Worker/Function, guarda a chave, aplica limites) → AI Gateway (registros, cache, teto de gasto) → API da xAI (Grok)

Os termos do GitHub Pages também proíbem uso primariamente comercial ou como serviço (SaaS) e transações sensíveis. Um bot institucional e informativo, com o processamento fora do Pages, é compatível; cobrança de usuários ou coleta de dados sensíveis pelo site não é.

1. Opções de onde e como o bot é renderizado

As opções não são excludentes. A arquitetura recomendada separa a **interface** (site, WhatsApp, Telegram, GitHub) do **núcleo** (proxy com a chave, instruções do bot e limites), de modo que um mesmo núcleo atenda vários canais.

Opção	Onde é renderizado	Ideal para	Impacto	Complexidade
A. Módulo no via-hub	Página ou widget de chat no próprio site (GitHub Pages, domínio iniciativa-via.com); requer proxy.	Presença pública da VIA, letramento digital, perguntas sobre o manifesto, o pipeline e os projetos.	4/5	2/5
B. GitHub App	Bot que comenta em issues e pull requests do repositório; servidor recebe webhooks.	Triagem de issues, revisão de PRs, checagem de textos e de consistência do site.	3/5	3/5
C. Cloudflare Workers + AI Gateway	Não é uma interface: é o servidor que guarda a chave e atende A, B, E e F.	Proxy seguro, limites de uso, registros e teto de gasto com o menor custo fixo.	5/5	2/5
D. Vercel (Functions + AI SDK / AI Gateway)	Servidor alternativo; pode também hospedar uma interface Next.js própria.	Interface de chat mais rica (streaming, histórico) com o AI SDK; equipe já habituada a Next.js.	3/5	3/5
E. WhatsApp Business	Conversa no WhatsApp, no número institucional +55 16 99618-0196 (via Cloud API da Meta ou Twilio).	Atendimento institucional a quem não navega em sites: dúvidas frequentes, agenda, encaminhamento a humano.	5/5	4/5
F. Telegram	Conversa em bot do Telegram, criado via @BotFather; webhook no Worker.	Protótipo rápido e gratuito, grupos de estudo, testes internos antes do WhatsApp.	2/5	1/5

Escala de impacto (ganho potencial de qualidade e alcance)

Nota	Significado
1	Ganho marginal; útil apenas para teste ou para um grupo muito restrito.
2	Ganho localizado; alcance pequeno ou público já atendido por outros meios.
3	Ganho claro em uma frente (técnica ou de comunicação), com alcance moderado.
4	Ganho relevante e visível para o público da VIA, sob marca própria.
5	Ganho estrutural: viabiliza outras frentes ou alcança o maior público possível.

Complexidade segue a mesma escala (1 = configuração simples; 5 = integração com aprovação de terceiros, políticas e operação contínua). A execução técnica fica a cargo do agente; a nota indica esforço e risco, não tarefa para o mantenedor.

Justificativa das notas

A. Módulo no via-hub — 4/5. Alcança quem já visita o site, sob a marca e o domínio da VIA, com conteúdo curado. Não chega a quem não visita o site.

B. GitHub App — 3/5. Ganho de qualidade técnica real, mas interno e parcialmente sobreposto a Codex e Copilot, já usados no repositório.

C. Cloudflare Workers + AI Gateway — 5/5. É a peça que viabiliza com segurança todas as outras opções; sem cobrança de tráfego e com plano gratuito generoso.

D. Vercel (Functions + AI SDK / AI Gateway) — 3/5. Mesmo resultado funcional do Workers, com custo fixo maior (Pro US\$ 20/assento); Hobby não admite uso comercial.

E. WhatsApp Business — 5/5. Maior alcance no Brasil, mas com custo por mensagem, aprovação da Meta e restrição a assistentes de uso geral.

F. Telegram — 2/5. API gratuita e simples, porém com alcance bem menor que o WhatsApp no público brasileiro.

2. Detalhes por plataforma

GitHub Pages (interface da opção A)

- Suporta domínio próprio com HTTPS — o via-hub já usa iniciativa-via.com/via-hub/.
- Limites: site de até 1 GB e cerca de 100 GB/mês de banda (limite flexível). Um widget de chat é leve.
- Não executa código no servidor: não guarda segredos e não chama a xAI diretamente.
- Não se destina a SaaS, comércio eletrônico ou transações sensíveis.

GitHub App (opção B)

- Permissões finas por repositório, tokens de curta duração e identidade de bot que não ocupa assento pago.
- Recebe eventos issues, pull_request e issue_comment por webhook; precisa de um servidor para recebê-los (o mesmo Worker ou Function).
- Conforme AGENTS.md, comentários do bot não contam como revisão independente nem autorizam merge.

Cloudflare Workers + AI Gateway (opção C)

- Free: 100 mil requisições/dia e 10 ms de CPU por requisição. A espera pela resposta da xAI não conta como CPU.
- Paid: US\$ 5/mês com 10 milhões de requisições e 30 milhões de CPU-ms incluídos; excedente de US\$ 0,30 por milhão de requisições e US\$ 0,02 por milhão de CPU-ms. **Sem cobrança de tráfego de saída (egress).**
- AI Gateway: análise de uso, cache e limitação de requisições gratuitos; registros de 100 mil (Free) ou 10 milhões por gateway (Paid). Unified Billing cobra 5% sobre créditos comprados, sem acréscimo por token; com chave própria da xAI, essa taxa não se aplica.

Vercel (opção D)

- Hobby: gratuito, apenas uso pessoal e não comercial; 1 milhão de invocações, 4 h de CPU e 360 GB-h; ao exceder, o projeto é pausado.
- Pro: US\$ 20/mês por assento, com US\$ 20 de crédito de uso. Invocações a US\$ 0,60/milhão; CPU ativa ≈ US\$ 0,128/h (iad1, EUA) e ≈ US\$ 0,221/h (gru1, São Paulo).
- AI Gateway da Vercel: sem acréscimo sobre tokens, inclusive com chave própria (BYOK, que exige créditos comprados); crédito mensal gratuito no plano free; orçamentos por projeto.

WhatsApp Business (opção E)

- Desde 01/10/2026 a Meta cobra por **mensagem de serviço** (resposta dentro da janela de 24 h aberta pelo usuário), com **1.000 mensagens de serviço gratuitas por mês por número** (fonte oficial Meta). Templates de utilidade dentro da janela também passam a ser cobrados.
- Valor de lista no Brasil: R\$ 0,035 por mensagem de serviço em conta faturada em reais (≈ US\$ 0,0068 em conta em dólar). **Este valor foi confirmado apenas em fontes secundárias;** a tabela oficial (rate card) da Meta é um arquivo para download e deve ser conferida antes da decisão.
- Via Twilio há taxa adicional por mensagem, **não verificada** nesta revisão. A Cloud API direta da Meta não tem essa taxa intermediária.

- Termos da Meta (desde 15/01/2026) proíbem provedores de IA de oferecer assistente de **uso geral** como função principal no WhatsApp Business; uso empresarial com escopo definido continua permitido. Há exceção atual para números do Brasil e do EEE, sujeita a mudança.

Telegram (opção F)

- Bot API gratuita; o bot é criado no @BotFather e ligado ao Worker por webhook (HTTPS, portas 443/80/88/8443).
- Limites de envio: cerca de 1 mensagem/s por conversa, 20/min em grupos e 30/s em difusão. Difusão paga (Telegram Stars) só se aplica a bots com mais de 100 mil usuários ativos mensais.

Custos da API xAI (Grok) e cenários mensais

Referência: 02/10/2026. Câmbio US\$ 1 = R\$ 5,23 (OEB, cotação de compra). Valores em R\$ incluem IOF de 3,5% sobre pagamento em dólar com cartão. Mensagem típica: 2.000 tokens de entrada e 500 de saída. Web search: 1 chamada por mensagem (US\$ 0,005). Cache: 1.500 dos 2.000 tokens de entrada. Hospedagem: Cloudflare Workers Paid (US\$ 5,00/mês) ou Vercel Pro (US\$ 20,00/mês).

Preço por 1 milhão de tokens (xAI, prompts abaixo de 200 mil tokens)

Modelo	Entrada	Entrada em cache	Saída	Contexto	Mensagem típica
grok-4.6	US\$ 2,00	US\$ 0,50	US\$ 6,00	500k	US\$ 0,00700 R\$ 0,0379
grok-4.5	US\$ 2,00	US\$ 0,30	US\$ 6,00	—	US\$ 0,00700 R\$ 0,0379
grok-4.3	US\$ 1,25	US\$ 0,20	US\$ 2,50	1M	US\$ 0,00375 R\$ 0,0203
grok-4.20	US\$ 1,25	US\$ 0,20	US\$ 2,50	1M	US\$ 0,00375 R\$ 0,0203
grok-build-0.1	US\$ 1,00	US\$ 0,20	US\$ 2,00	—	US\$ 0,00300 R\$ 0,0162

Custo de tokens por mês

Modelo e ferramentas	Por mensagem	1.000 msg/mês	10.000 msg/mês	100.000 msg/mês
grok-4.6	US\$ 0,00700	US\$ 7,00 R\$ 37,89	US\$ 70,00 R\$ 378,91	US\$ 700,00 R\$ 3.789,14
grok-4.6 + web search	US\$ 0,01200	US\$ 12,00 R\$ 64,96	US\$ 120,00 R\$ 649,57	US\$ 1.200,00 R\$ 6.495,66
grok-4.6 com cache (1.500 tokens)	US\$ 0,00475	US\$ 4,75 R\$ 25,71	US\$ 47,50 R\$ 257,12	US\$ 475,00 R\$ 2.571,20
grok-4.3	US\$ 0,00375	US\$ 3,75 R\$ 20,30	US\$ 37,50 R\$ 202,99	US\$ 375,00 R\$ 2.029,89
grok-4.3 + web search	US\$ 0,00875	US\$ 8,75 R\$ 47,36	US\$ 87,50 R\$ 473,64	US\$ 875,00 R\$ 4.736,42

Total mensal estimado

Total mensal (tokens + hospedagem + canal)	1.000 msg/mês	10.000 msg/mês	100.000 msg/mês
Site + Workers Paid + grok-4.6	US\$ 12,00 R\$ 64,96	US\$ 75,00 R\$ 405,98	US\$ 705,00 R\$ 3.816,20
Site + Workers Paid + grok-4.6 + web search	US\$ 17,00 R\$ 92,02	US\$ 125,00 R\$ 676,63	US\$ 1.205,00 R\$ 6.522,73
Site + Workers Paid + grok-4.3	US\$ 8,75 R\$ 47,36	US\$ 42,50 R\$ 230,05	US\$ 380,00 R\$ 2.056,96
Site + Vercel Pro + grok-4.6	US\$ 27,00 R\$ 146,15	US\$ 90,00 R\$ 487,17	US\$ 720,00 R\$ 3.897,40
WhatsApp + Workers Paid + grok-4.6*	US\$ 12,00 R\$ 64,96	US\$ 136,20 R\$ 737,26	US\$ 1.378,20 R\$ 7.460,27
Telegram + Workers Paid + grok-4.6	US\$ 12,00 R\$ 64,96	US\$ 75,00 R\$ 405,98	US\$ 705,00 R\$ 3.816,20

* WhatsApp: 1.000 mensagens de serviço grátis por mês por número e US\$ 0,0068 por mensagem excedente (valor de fontes secundárias, não verificado no rate card oficial; sem taxa de intermediário). Fontes: docs.x.ai/developers/pricing; developers.cloudflare.com/workers/platform/pricing; vercel.com/pricing; Meta, WhatsApp Business Platform pricing. Preços mudam; revalidar antes de contratar.

4. Detalhes de custo

Ferramentas executadas no servidor da xAI

Ferramenta	Preço	Por chamada	Uso típico no bot
web_search, x_search, code_execution	US\$ 5,00 / 1.000	US\$ 0,0050	Buscar informação atual na web ou no X
attachment_search	US\$ 10,00 / 1.000	US\$ 0,0100	Buscar dentro de arquivos anexados
collections_search (RAG)	US\$ 2,50 / 1.000	US\$ 0,0025	Responder com base nos documentos da VIA

grok-4.6 com prompts a partir de 200 mil tokens: US\$ 4,00 entrada, US\$ 1,00 cache, US\$ 12,00 saída. A Batch API (processamento não imediato) tem desconto. Um token equivale, em média, a cerca de três quartos de uma palavra em inglês; em português, a proporção é um pouco menor.

Custo de hospedagem e canal

Hospedagem e canal (somar ao custo de tokens)	1.000 msg/mês	10.000 msg/mês	100.000 msg/mês
Cloudflare Workers Free (até 100 mil req/dia)	US\$ 0,00	US\$ 0,00	US\$ 0,00
Cloudflare Workers Paid (recomendado)	US\$ 5,00	US\$ 5,00	US\$ 5,00
Vercel Pro, 1 assento	US\$ 20,00	US\$ 20,00	US\$ 20,00
Telegram Bot API	US\$ 0,00	US\$ 0,00	US\$ 0,00
WhatsApp, mensagens de serviço	US\$ 0,00	US\$ 61,20	US\$ 673,20
GitHub Pages (interface)	US\$ 0,00	US\$ 0,00	US\$ 0,00

Premissas: Workers com 5 ms de CPU por requisição; Vercel com 50 ms de CPU ativa em gru1 — o uso estimado (US\$ 0,37 em 100 mil mensagens) fica dentro do crédito de US\$ 20 do plano Pro. WhatsApp: uma resposta do bot por mensagem do usuário; taxa da Twilio ou de outro intermediário não verificada. Em conta WhatsApp faturada em reais (R\$ 0,035 por mensagem) não há IOF.

Controle de custo na prática

- Cada resposta da xAI informa o custo real da requisição no campo **usage.cost_in_usd_ticks**; o proxy pode somar esse valor e bloquear novas chamadas ao atingir um teto diário ou mensal.
- Usar **prompt_cache_key** para que o prompt de sistema e o histórico estável sejam cobrados como entrada em cache (US\$ 0,50 em vez de US\$ 2,00 por milhão no grok-4.6).
- Limitar o tamanho das respostas e o número de chamadas de ferramenta por mensagem.

GitHub App (opção B): referência separada

Revisões de pull request usam contexto maior. Premissa: 300 eventos/mês, 20.000 tokens de entrada e 2.000 de saída cada, com grok-4.6: US\$ 0,052 por evento, cerca de **US\$ 15,60/mês** (R\$ 84,44), mais a hospedagem do webhook (Workers Free ou Paid).

5. Imprimir a tabela por comando de voz (Alexa)

Objetivo: dizer “Alexa, imprima a tabela do Grok Bot” e receber em papel a página de custos (seção 3). Caminho recomendado: **skill privada em pt-BR hospedada pela Amazon → Worker na Cloudflare com token e limite diário → Resend → Epson Email Print com lista de remetentes aprovados**. Custo fixo de nuvem zero, sem certificação e sem validar a assinatura da Alexa num endpoint próprio.

Achados críticos

- A impressão nativa da Alexa só imprime modelos prontos (listas, jogos, papel pautado); não imprime PDF externo e não oferece API para skills. A skill “Epson Printer” para Alexa foi descontinuada em 31/03/2025.
- Impressoras HP lançadas após o outono de 2020 não têm ePrint (impressão por e-mail); a HP DeskJet Ink Advantage 2874, a mais barata nas lojas, não serve. A Epson é o único fabricante com Email Print verificado e ativo no Brasil.
- A Amazon envia periodicamente um LaunchRequest de verificação (usuário alexa-lambda-availability) às skills hospedadas por ela. Sem filtro, a impressora imprime sozinha.
- A recarga automática mínima de créditos xAI é US\$ 5; o mínimo da compra manual não está na página consultada (não verificado; versão anterior citava US\$ 25). Créditos pré-pagos não são reembolsáveis.
- A integração nativa Alexa-IFTTT foi encerrada em 31/10/2023; não usar.

Orçamento em três níveis (referência 02/10/2026; itens em dólar com IOF de 3,5%)

Nível	Composição	Investimento inicial	Custo mensal estimado
0 — Indispensável	Créditos xAI pré-pagos (recarga mínima de US\$ 5); contas gratuitas da Cloudflare (Workers Free), Amazon Developer (skill hospedada pela Amazon) e Resend; domínio, celular e internet já existentes.	≈ R\$ 27,07	≈ R\$ 20,30 (1.000 mensagens com grok-4.3)
1 — Mínimo viável	Nível 0 + Echo Pop (≈ R\$ 379) + Epson EcoTank L1250 com Email Print (≈ R\$ 849) + papel A4 (≈ R\$ 30).	≈ R\$ 1.285	≈ R\$ 22,43 (API + 30 páginas a ≈ R\$ 0,07)
2 — Confortável	Echo Show 5, 3ª geração (≈ R\$ 849) + Epson EcoTank L3250 multifuncional (≈ R\$ 1.019) + papel + US\$ 25 em créditos xAI (≈ R\$ 135,33).	≈ R\$ 2.033	≈ R\$ 22,43, ou ≈ R\$ 40,03 com grok-4.6

Custo mensal considera Workers Free. Se o proxy do Grok Bot usar Workers Paid, somar ≈ R\$ 27,07/mês. Alexa+ não é necessária. Custo por página em preto: tinta ≈ R\$ 0,011 + papel ≈ R\$ 0,06 = ≈ R\$ 0,07.

Itens e preços de referência

Item	Preço	Fonte e data	Situação
Créditos xAI, recarga automática mínima	US\$ 5,00 ≈ R\$ 27,07	docs.x.ai/console/billing	Verificado; mínimo da compra manual não verificado
Echo Pop	R\$ 379,00	Amazon.com.br, preço de tabela jun-jul/2026 (mínimo visto R\$ 340,20)	Preço de hoje não verificado
Epson EcoTank L1250 (Wi-Fi, Email Print)	R\$ 849,00	Carrefour.com.br, 02/10/2026 (faixa R\$ 799-949)	Verificado por busca

Item	Preço	Fonte e data	Situação
Papel A4, 500 folhas	R\$ 30,00	—	Estimativa, não verificado
Echo Show 5 (3ª geração)	R\$ 849,00	Amazon.com.br, set/2026 (Buscapé: R\$ 641,79)	Verificado por busca
Epson EcoTank L3250 (multifuncional)	R\$ 1.018,72	Amazon.com.br, set/2026 (Kalunga e Nagem: R\$ 1.099)	Verificado por busca
Tinta Epson T544 preta, 65 ml	R\$ 50,29	Dec Distribuidora; rendimento de 4.500 páginas	≈ R\$ 0,011 por página

Preços de varejo variam com promoções; conferir na data da compra.

Fluxo recomendado

1. O mantenedor diz: “Alexa, imprima a tabela do Grok Bot”.
2. Uma rotina do app Alexa reconhece a frase e abre a skill privada “Grok Bot” (pt-BR, uso próprio, estado “In Development”, sem certificação nem publicação na loja).
3. A skill, hospedada gratuitamente pela Amazon (Alexa-hosted), descarta o LaunchRequest de verificação periódica (usuário **alexa-lambda-availability**) e chama o Worker com um token de baixo privilégio.
4. O Worker na Cloudflare confere o token e o limite diário de impressões (destino fixo, sem parâmetros livres).
5. O Worker envia pelo Resend, a partir de um subdomínio de iniciativa-via.com, a página de custos (**tabela-custos-grok-bot.pdf**) ao endereço Epson Email Print da impressora.
6. O Epson Connect aceita apenas remetentes da lista de aprovados e envia o trabalho à impressora; se ela estiver desligada, o trabalho fica guardado por até 72 horas.
7. A página sai em cerca de 1 a 3 minutos (estimativa; a fila da Epson não tem tempo garantido).
8. A Alexa confirma o envio por voz (não a impressão). Num Echo Show, a tabela também aparece na tela.

Quem faz o quê

Etapas	O agente faz	Depende do mantenedor
Código da skill (modelo pt-BR, filtro da verificação periódica)	Sim	—
Código do Worker (token, limite diário, envio pelo Resend) e testes	Sim	—
Conta Amazon Developer, com a mesma conta Amazon do Echo	—	Criar (grátis) e aceitar os termos
Criar a skill no console e ativar o teste em “Development”	Prepara o pacote para o ASK CLI	Login e aceite
Conta Resend e registros DNS do subdomínio	Gera a lista exata de registros	Criar a conta; incluir os registros ou conceder token Cloudflare restrito a DNS
Publicar o Worker e cadastrar os secrets	Sim, com acesso autorizado	Autorizar o acesso, se ainda não houver
Comprar e instalar impressora e Echo no Wi-Fi	—	Sim
Ativar Epson Connect e lista de remetentes aprovados	Escreve o passo a passo	Sim (conta Epson)
Informar o e-mail da impressora ao Worker (secret)	—	Sim

Etapa	O agente faz	Depende do mantenedor
Criar a rotina no app Alexa	Escreve o passo a passo	Sim (cerca de 2 minutos)

Limites e pontos não verificados

- Que a ação personalizada de uma rotina abra uma skill em desenvolvimento é provável, mas não verificado. Alternativa: “Alexa, peça ao Grok Bot para imprimir a tabela”.
- Compatibilidade da Alexa+ (acesso antecipado no Brasil desde 18/06/2026) com skills em desenvolvimento em pt-BR: não verificada.
- Custo do Epson Connect: não anunciado (não verificado formalmente). Impressão por e-mail de Canon e Brother no Brasil: não verificada.
- Variante: se o proxy já estiver no Workers Paid, o Cloudflare Email Service (beta) pode substituir o Resend; no plano gratuito ele só envia a endereços verificados, o que a impressora não consegue fazer.
- Risco de spam no e-mail da impressora: mitigado pela lista de remetentes aprovados e pelo sigilo do endereço.

6. Riscos e conformidade

Dados de saúde e LGPD

- Dados de saúde são **dados pessoais sensíveis** (LGPD, art. 5º, II, e art. 11). O bot **não deve receber nem enviar à xAI dados identificáveis de pacientes**: nome, CPF, prontuário, datas, telefone, imagens ou relatos que permitam identificar alguém.
- Avisar na interface, antes do primeiro uso, que o bot é informativo, não faz diagnóstico nem substitui consulta, e que não se deve digitar dados de pacientes.
- O proxy pode aplicar filtro simples (CPF, telefone, e-mail) e recusar a mensagem antes do envio à xAI.
- Publicar política de privacidade do bot: o que é registrado, por quanto tempo, e que o processamento ocorre fora do Brasil (transferência internacional, LGPD art. 33). Configurar retenção curta de registros no AI Gateway.
- A conduta ética médica (CFM) também se aplica à comunicação pública de um médico: o bot não deve prometer resultados nem fazer orientação clínica individual.

HUMAN_GATE

- Respostas sobre condutas clínicas, casos individuais ou temas jurídicos devem encaminhar a um humano em vez de responder.
- No GitHub App, o bot comenta e sugere; merge e publicação continuam sendo decisão do mantenedor (AGENTS.md).
- Mudanças nas instruções do bot (prompt de sistema) passam por PR revisado, como o restante do site.

Gasto e abuso

- Teto de gasto em três camadas: limite de crédito na conta xAI, limitação de requisições no AI Gateway e contador de **cost_in_usd_ticks** no proxy que bloqueia ao atingir o teto.
- Limite por visitante (por exemplo, 20 mensagens/hora) e Cloudflare Turnstile contra robôs.
- A chave da xAI existe apenas como segredo do servidor; nunca no repositório, que é público.

Plataformas

- GitHub Pages: uso institucional e informativo; nada de cobrança ou SaaS hospedado no Pages.
- Vercel Hobby: vedado para uso comercial; se a VIA tiver caráter comercial, usar Pro.
- WhatsApp: manter o bot com escopo institucional definido (não um assistente de uso geral), cumprir opt-out e política de mensagens; risco de suspensão do número se os termos forem violados. Recomenda-se um número dedicado ao bot para não arriscar o número principal.

7. Próximos passos

O que depende do mantenedor

#	Decisão ou ação	Por que só o mantenedor pode fazer
1	Criar conta na xAI (console.x.ai), cadastrar forma de pagamento, definir limite de crédito e gerar a XAI_API_KEY.	Conta, pagamento e aceite de termos são pessoais.
2	Adicionar a chave como segredo: Cursor Dashboard → Cloud Agents → Secrets (nome XAI_API_KEY). O agente a transfere para o segredo do Worker sem expô-la.	Envolve credencial e cobrança.
3	Escolher o canal inicial: site (recomendado), Telegram, WhatsApp ou GitHub App.	Decisão substantiva de produto.
4	Definir o teto de gasto mensal (por exemplo, US\$ 20) e o escopo do bot (o que responde e o que encaminha).	Decisão de orçamento e de conteúdo.

#	Decisão ou ação	Por que só o mantenedor pode fazer
5	Se escolher Cloudflare: criar conta ou autorizar acesso do agente; se WhatsApp: conta Meta Business verificada e número dedicado.	Contas de terceiros e infraestrutura externa (HUMAN_GATE).
6	Opcional, impressão por voz: escolher o nível de orçamento (seção 5), comprar os aparelhos e criar as contas Amazon Developer, Epson Connect e Resend.	Compra de equipamento e contas pessoais.

O que o agente executa depois das decisões

- Worker proxy com a chave como segredo, AI Gateway, limites, filtro de dados pessoais e teto por **cost_in_usd_ticks**.
- Módulo de chat no via-hub com aviso de uso, seguindo a identidade visual do site, em PR draft para revisão.
- Prompt de sistema com o conteúdo da VIA e regras de encaminhamento humano, versionado no repositório.
- Testes com volume pequeno e relatório de custo real antes de abrir ao público.
- Expansão para Telegram, WhatsApp ou GitHub App reaproveitando o mesmo núcleo, conforme decisão.

Fontes consultadas

- xAI — Models and Pricing: docs.x.ai/developers/pricing (preços por token, ferramentas, cost_in_usd_ticks, cache).
- Cloudflare Workers — Pricing: developers.cloudflare.com/workers/platform/pricing.
- Cloudflare AI Gateway — Pricing: developers.cloudflare.com/ai-gateway/reference/pricing.
- Vercel — Pricing e Fair use: vercel.com/pricing; vercel.com/docs/limits/fair-use-guidelines.
- Vercel AI Gateway — Pricing: vercel.com/docs/ai-gateway/pricing.
- GitHub Pages — Limits e uso: docs.github.com/pages/getting-started-with-github-pages/github-pages-limits.
- GitHub Apps — About creating GitHub Apps: docs.github.com/apps/creating-github-apps.
- Meta — Pricing on the WhatsApp Business Platform: developers.facebook.com/documentation/business-messaging/whatsapp/pricing (cobrança de mensagens de serviço e franquia de 1.000/mês a partir de 01/10/2026).
- WhatsApp Business Solution Terms, seção AI Providers: whatsapp.com/legal/business-solution-terms.
- Valor R\$ 0,035 / US\$ 0,0068 por mensagem de serviço no Brasil: fontes secundárias (wizebot.com.br, clickmassa.com.br) que reproduzem o rate card oficial de 01/10/2026 — conferir no rate card da Meta.
- Telegram — Bots FAQ: core.telegram.org/bots/faq (API gratuita, limites de envio).
- LGPD — Lei nº 13.709/2018, arts. 5º, 11 e 33.
- Câmbio: OEB, cotação de compra de 02/10/2026 (US\$ 1 = R\$ 5,23); Agência Brasil, dólar à vista R\$ 5,224 em 01/10/2026. IOF de 3,5% em compras no exterior: Decreto nº 12.499/2025.
- Alexa Skills Kit: developer.amazon.com/en-US/docs/alexa — Test and Submit Your Skill; Hosted Skills Usage Limits; Create and Manage Alexa-Hosted Skills (verificação alexa-lambda-availability); Integrate Custom Task with Routines.
- Impressão nativa da Alexa: Amazon Forum (out/2024) e TechCrunch (10/09/2020). Skill Epson Printer descontinuada: epson.com/Support/voice. IFTTT: help.ifttt.com/hc/en-us/articles/19823288619419.
- Epson Connect / Email Print: epson.com.br/epson-connect-impressao-wireless; manuais L1250 e L3250. HP ePrint: support.hp.com/us-en/document/ish_2060244-1929404-16.
- Resend: resend.com/pricing. Cloudflare Email Service: developers.cloudflare.com/email-service. Créditos xAI: docs.x.ai/console/billing.
- Preços de varejo: Amazon.com.br, Carrefour.com.br, Buscapé, Kalunga, Nagem e Dec Distribuidora (jun-out/2026).

Não verificado nesta revisão: taxa por mensagem da Twilio para WhatsApp; rate card oficial da Meta em arquivo (valor em reais obtido de fontes secundárias); mínimo da compra manual de créditos xAI; preço atual do Echo Pop; preço do papel; custo do Epson Connect; abertura de skill em desenvolvimento por rotina; compatibilidade da Alexa+. O câmbio é referência datada e oscila; o IOF pode mudar por decreto. Preços mudam; revalidar antes de contratar. Preços coletados em 02/10/2026 por agente de IA a partir de grok/bot/gerar_pdf_opcoes.py.